

# Projekt Jakub Klimek

July 4, 2025

## 1 Wstęp

### 1.1 Źródło danych

Analiza została przeprowadzona na dwóch zbiorach danych z angielskiej ligi piłkarskiej Premier League:

- **Sezon 2020/2021** (“sezon covidowy”) - dane z [Kaggle](#) (524 piłkarzy)
- **Sezon 2023/2024** (powrót do normalności) - dane z [Kaggle](#) (570 piłkarzy)

Zbiory zawierają indywidualne statystyki piłkarzy takie jak:

- Statystyki dyscyplinarne (żółte kartki, faule)
- Dane ofensywne (gole, strzały, przewidywana liczba goli xG)
- Liczbę rozegranych meczów przez zawodników

### 1.2 Cel analizy i hipoteza

Sezon 2020/21 rozgrywano **bez udziału publiczności** z powodu pandemii COVID-19, co stanowiło bezprecedensową sytuację w 128-letniej historii angielskiej ligi. Głównym celem badania jest sprawdzenie, jak ta wyjątkowa okoliczność wpłynęła na zachowania piłkarzy na boisku.

**Kontekst:**

- Pierwszy w historii sezon bez kibiców (od marca 2020 do maja 2021)
- Mecze rozgrywane w “sterylnych” warunkach (tylko sztuczny doping)
- Zawodnicy zgłaszały problemy z motywacją (źródło: wywiady BBC Sport)

**Wartość naukowa:** Analiza pozwala zbadać:

- Rzadką okazję naturalnego eksperymentu społecznego
- Obiektywny wpływ presji tłumu na dynamikę gry
- Efekt “cichego boiska” na podejmowanie decyzji taktycznych

**Główna hipoteza:** “Brak presji kibiców w sezonie 2020/21 wpłynął na lepszą organizację defensywą, co przełożyło się na:

- Mniejszą liczbę żółtych kartek (wynikającą z precyzyjniejszych interwencji obrońców)
- Niższą skuteczność ofensywną przeciwników (mniej błędów defensywnych → mniej straconych goli mimo podobnych xG)”

*Expected Goals (xG):* Metryka statystyczna określająca prawdopodobieństwo strzelania gola z danej sytuacji, uwzględniająca m.in. dystans do bramki, kąt strzału, część ciała i rodzaj akcji. Wartość 0.3 xG oznacza np. 30% szans na gola w danej sytuacji.

## 2 Analiza rozkładu przy pomocy metryk statystycznych

### 2.1 Kwantyle

#### Definicja:

Wartości dzielące zbiór danych na części

#### Wyniki:

Kwantyl	2020/21	2023/24
Q1	1	1
Q2 (mediana)	2	2
Q3	3	4
90%	5	6

#### Interpretacja:

- Stabilność dolnej połowy rozkładu (Q1-Q2) sugeruje, że dla **typowego zawodnika** liczba kartek nie uległa zmianie. Różnice występują głównie wśród zawodników często faulujących(tzw. “policjanci”) oraz specjalistów od gry zatrzymującej (znaczny wzrost w górnych partiach - Q3 i powyżej)

### 2.2 Średnia arytmetyczna

#### Definicja:

Średnia liczba żółtych kartek na zawodnika w sezonie

#### Wzór:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

#### Wyniki:

- Sezon 2020/21: **2.11**
- Sezon 2023/24: **2.85** (*wzrost o 35%*)

#### Interpretacja:

Wzrost średniej o **35%** wskazuje na znaczący wzrost liczby żółtych kartek w sezonie 2023/24. Może to wynikać z:

- Większej presji psychicznej
- Większej intensywności gry przy pełnych trybunach
- Zmian taktycznych (np. popularność pressingów)

## 2.3 Średnia harmoniczna

### Definicja:

Średnia stosowana dla danych o charakterze stosunków lub współczynników

### Wzór:

$$H = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

### Wyniki:

- Sezon 2020/21: **1.54**
- Sezon 2023/24: **1.92** (*wzrost o 25%*)

### Interpretacja:

Niższe wartości niż średnia arytmetyczna wskazują na:

- Silny wpływ wartości skrajnie wysokich
- Większą wrażliwość na ekstremum w sezonie 2023/24

## 2.4 Średnia geometryczna

### Definicja:

Średnia stosowana dla danych o charakterze proporcjonalnym

### Wzór:

$$G = \left( \prod_{i=1}^n x_i \right)^{1/n}$$

### Wyniki:

- Sezon 2020/21: **1.78**
- Sezon 2023/24: **2.31** (*wzrost o 30%*)

### Interpretacja:

Potwierdza ogólny trend wzrostowy przy:

- Mniejszej wrażliwości na ekstremum niż średnia arytmetyczna
- Lepszym odzwierciedleniu typowych wartości

## 2.5 Średnia ucinana (10%)

### Definicja:

Średnia obliczona po odrzuceniu 10% skrajnych wartości

### Wzór:

$$\bar{x}_{tr} = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} x_i$$

### **Wyniki:**

- Sezon 2020/21: **1.98**
- Sezon 2023/24: **2.52** (*wzrost o 27%*)

### **Interpretacja:**

Mniejszy wzrost niż dla pełnej średniej sugeruje:

- Znaczący udział wartości skrajnych w różnicy między sezonami
- Względną stabilność “rdzenia” rozkładu

## **2.6 Średnia winsorowska (10%)**

### **Definicja:**

Średnia gdzie skrajne wartości są zastępowane percentylami

### **Wzór:**

$$\bar{x}_w = \frac{1}{n} \left( (k+1)x_{(k+1)} + \sum_{i=k+2}^{n-k+1} x_i + (k+1)x_{(n-k)} \right)$$

### **Wyniki:**

- Sezon 2020/21: **2.03**
- Sezon 2023/24: **2.61** (*wzrost o 29%*)

### **Interpretacja:**

Potwierdza wnioski ze średniej ucinanej przy:

- Zachowaniu pełnej liczby obserwacji
- Mniejszej wrażliwości na ekstremę

## **2.7 Współczynnik skośności**

### **Definicja:**

Miara asymetrii rozkładu

### **Wzór:**

$$\alpha = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \left( \frac{x_i - \bar{x}}{S} \right)^3$$

### **Wyniki:**

- Sezon 2020/21: **1.26**
- Sezon 2023/24: **1.13**

### **Interpretacja:**

Dodatnia skośność (prawostronna) wskazuje na:

- Obecność piłkarzy z wysoką liczbą kartek
- W sezonie covidowym asymetria była bardziej wyraźna

## 2.8 Kurtoza

### Definicja:

Miara koncentracji danych wokół średniej

### Wzór:

$$K = \frac{E[(X - \mu)^4]}{\sigma^4}$$

### Wyniki:

- Sezon 2020/21: **4.53**
- Sezon 2023/24: **3.72**

### Interpretacja:

Wysokie wartości ( $>3$ ) oznaczają:

- “Spiczasty” rozkład z grubymi ogonami
- W sezonie 2020/21 większa koncentracja wyników wokół średniej

## 2.9 Odchylenie standardowe

### Definicja:

Miara rozproszenia danych wokół średniej

### Wzór:

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

### Wyniki:

- Sezon 2020/21: **2.27**
- Sezon 2023/24: **2.86**

### Interpretacja:

Wzrost odchylenia o **26%** pokazuje:

- Większe zróżnicowanie między “spokojnymi” a “agresywnymi” zawodnikami

## 2.10 Odchylenie przeciętne od średniej

### Definicja:

Średnie odchylenie od wartości średniej

### Wzór:

$$MD = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

### Wyniki:

- Sezon 2020/21: **1.82**
- Sezon 2023/24: **2.33** (*wzrost o 28%*)

### **Interpretacja:**

Współgra ze wzrostem odchylenia standardowego:

- Potwierdza większą zmienność wyników
- Wskazuje na rozproszenie wokół wyższej średniej

## **2.11 Wariancja**

### **Definicja:**

Średnia kwadratów odchyleń od średniej

### **Wzór:**

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

### **Wyniki:**

- Sezon 2020/21: **5.15**
- Sezon 2023/24: **8.18** (*wzrost o 59%*)

### **Interpretacja:**

Wyraźny wzrost zgodny z:

- Zaobserwowanym zwiększeniem rozrzutu
- Większą liczbą ekstremalnych przypadków

## **2.12 Rozstęp**

### **Definicja:**

Różnica między wartością maksymalną a minimalną

### **Wyniki:**

- Sezon 2020/21: **12**
- Sezon 2023/24: **13**

### **Wnioski:**

Ekstremalne przypadki (zawodnicy z  $>10$  kartkami) stały się jeszcze częstsze

## **2.13 Kluczowe wnioski**

1. **Wzrost agresji:** Średnia liczba kartek wzrosła o 35%, przy stabilnej medianie
2. **Zróżnicowanie taktyk:** Większe odchylenie wskazuje na różnicowanie stylów gry
3. **Ekstrema:** Wzrost maksymalnej liczby kartek (12→13) przy tym samym minimum (0)
4. **Stabilny wzorzec:** – Większość zawodników z niewielką liczbą kartek

**Kontekst sportowy:** Wyniki potwierdzają hipotezę o wpływie kibiców - powrót publiczności skorelowany jest z:

- Większą intensywnością gry
- Większą liczbą interwencji sędziowskich
- Większym zróżnicowaniem między stylami drużyn

### 3 Prezentacja rozkładów na wykresach

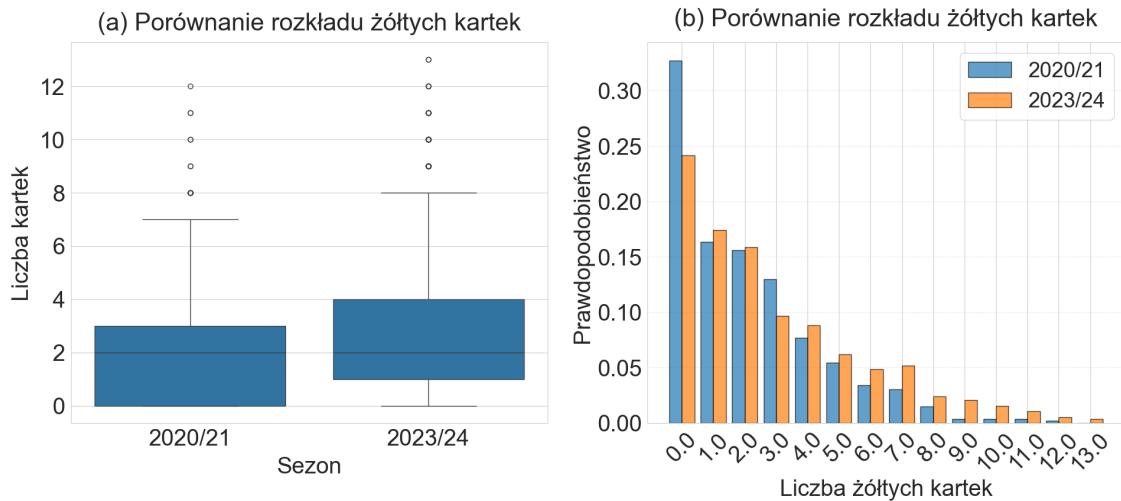
#### 3.1 Wprowadzenie metodologiczne

Do wizualizacji różnic między sezonami wykorzystano następujące typy wykresów:

**Wykres pudełkowy** - pokazuje medianę, kwartyle i wartości odstające, co pozwala na porównanie rozkładów w sposób odporny na ekstrema

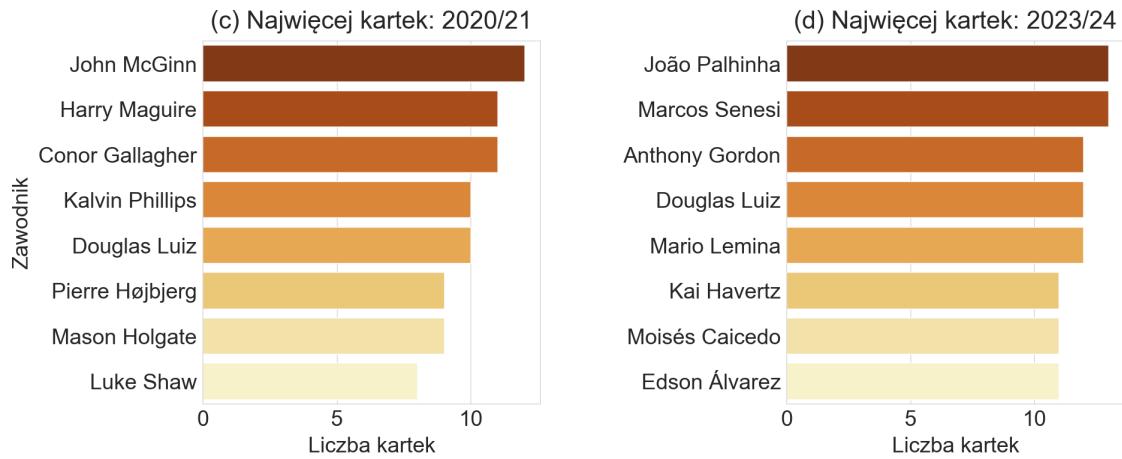
**Rozkład gęstości** - uwidacznia kształt rozkładu prawdopodobieństwa

**Dystrybuanta** - pokazuje skumulowane prawdopodobieństwo, umożliwia porównanie całych rozkładów i identyfikację różnic w prawdopodobieństwach dla różnych wartości.

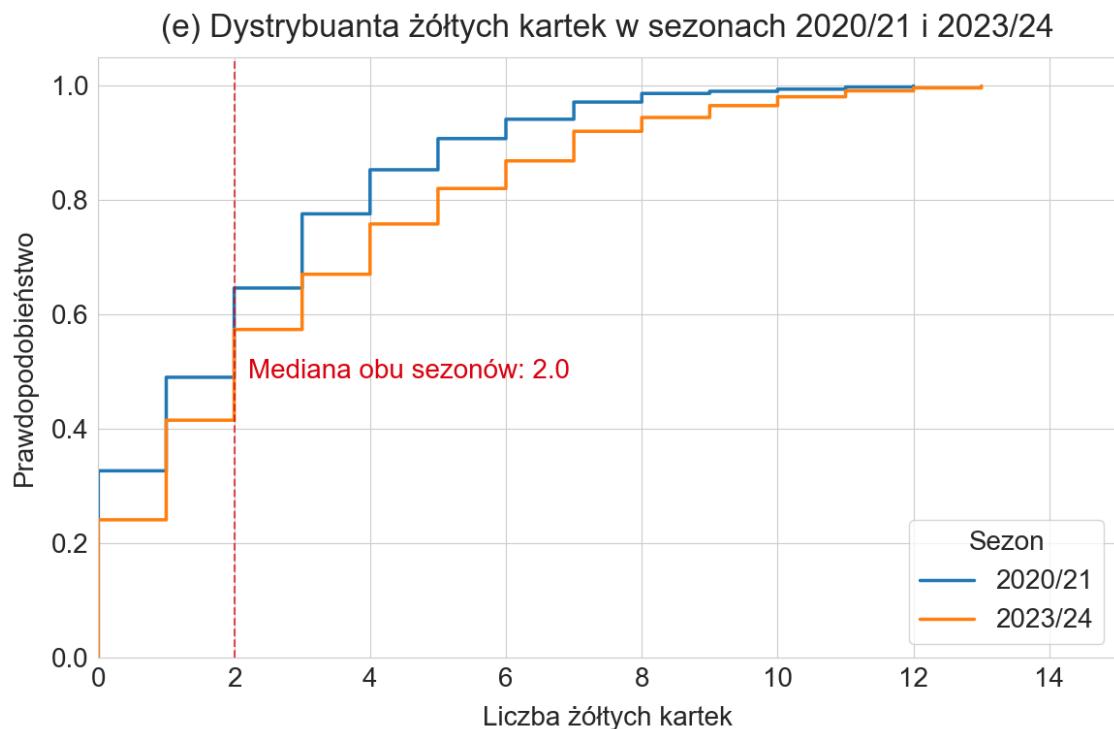


#### 3.2 Interpretacja wykresów

Mimo że mediana pozostała niezmieniona (2 kartki w obu sezonach), rozkład gęstości ujawnia znaczące różnice. W sezonie covidowym 2020/21 wyraźnie dominowała wartość 0, tworząc ostry szczyt rozkładu. Natomiast sezon 2023/24 prezentuje się zupełnie inaczej - rozkład jest wyraźnie spłaszczony, z mocno zaznaczonym prawym ogonem. To właśnie ta różnica jest najbardziej wymowna: zawodnicy z 5+ żółtymi kartkami występują niemal dwukrotnie częściej w sezonie z kibicami, co bezpośrednio przekłada się na wzrost średniej z 2.11 do 2.85 kartki na zawodnika. Zmiana ta jest szczególnie widoczna wśród najbardziej karnych piłkarzy, co dobrze ilustruje poniższy wykres przedstawiający liderów pod względem liczby żółtych kartek w obu sezonach.



Wykresy wyraźnie pokazują, że w sezonie 2023/24 nie tylko zwiększyła się liczba ekstremalnych przypadków, ale też wzrosła minimalna liczba kartek potrzebna do znalezienia się w czołówce. Podczas gdy w sezonie 2020/21 górna granica wynosiła 12 kartek, w ostatnim sezonie aż pięciu zawodników wyrównało lub przekroczyło ten wynik. Co więcej, minimalna liczba kartek potrzebna do znalezienia się w czołówce wzrosła z 8 do 11.



Dystrybuanta pokazuje, że w sezonie 2023/24 wzrosło prawdopodobieństwo otrzymania większej liczby kartek. Na początku i środku rozkładu widoczne są wyraźne różnice między sezonami, które stopniowo zmniejszają się dla wyższych wartości, gdzie krzywe niemal się zbiegają.

## 4 Dane wspierające hipotezę

Aby zweryfikować hipotezę, że obrońcy prezentowali wyższą skuteczność w sezonie 2020/21 (rozgrywanym bez kibiców), przeprowadziliśmy porównanie statystyk bramkowych w dwóch kluczowych wymiarach:

- Produktywność indywidualna – analiza liczby goli dla poszczególnych zawodników,
- Skuteczność drużynowa – porównanie średniej liczby goli na mecz w całej lidze między sezonami.

Wyniki wykazały istotną różnicę: w sezonie 2020/21 na mecz przypadało średnio 2.69 gola, podczas gdy w 2023/24 (z kibicami) wartość ta wzrosła do 3.28 gola. Ta znacząca zmiana sugeruje, że obecność kibiców mogła wpłynąć na tempo gry i skuteczność ataku, pośrednio potwierdzając naszą tezę o lepszej grze obrońców w warunkach ograniczonej presji zewnętrznej.

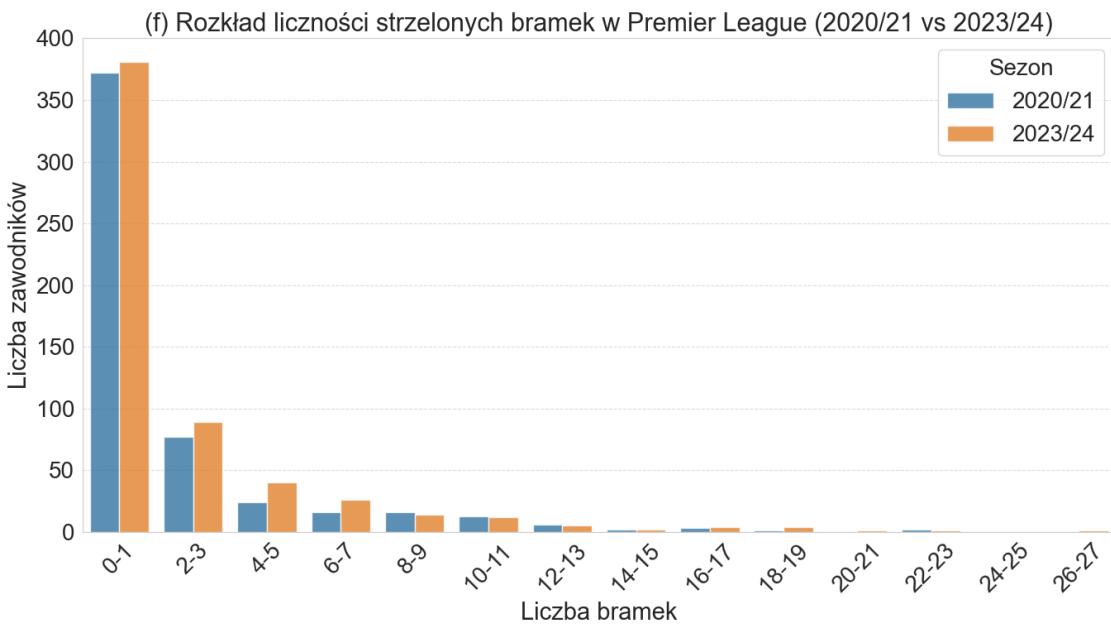
### 4.1 Produktywność indywidualna

Sprawdźmy, jak te zmiany wyglądają w ujęciu indywidualnym.

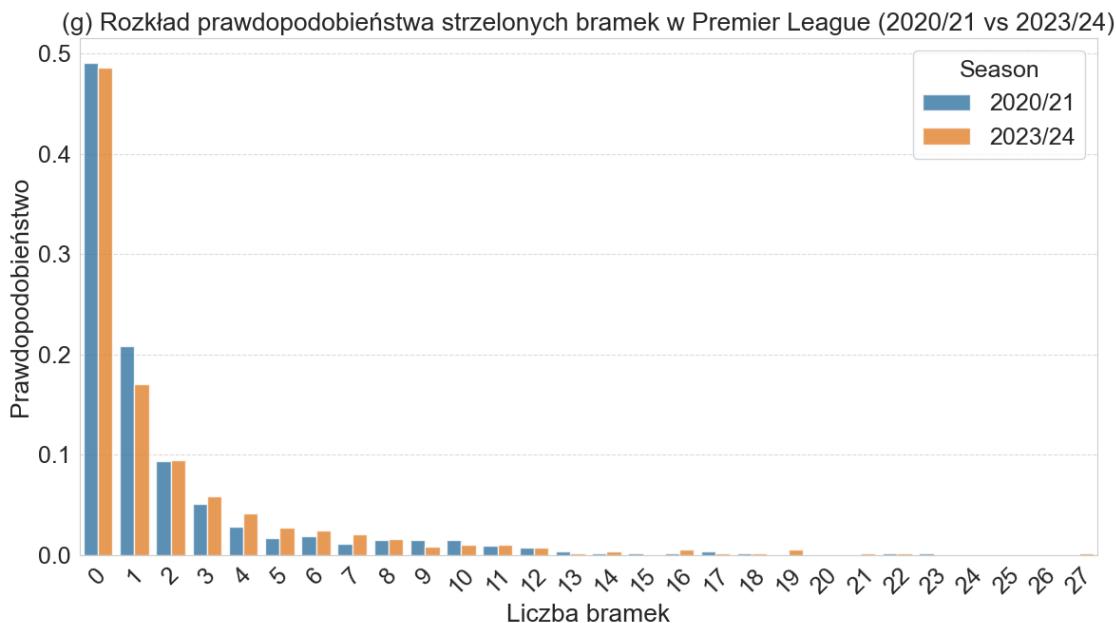
Statystyki liczby goli strzelonych przez zawodników

Statystyka	2020/21	2023/24
Średnia	1.85	2.06
Q1	0.0	0.0
Mediana	1.0	1.0
Q3	2.0	2.0
Średnia ucinana (10%)	1.02	1.2
Odchylenie standardowe	3.34	3.62
Wariancja	11.14	13.11

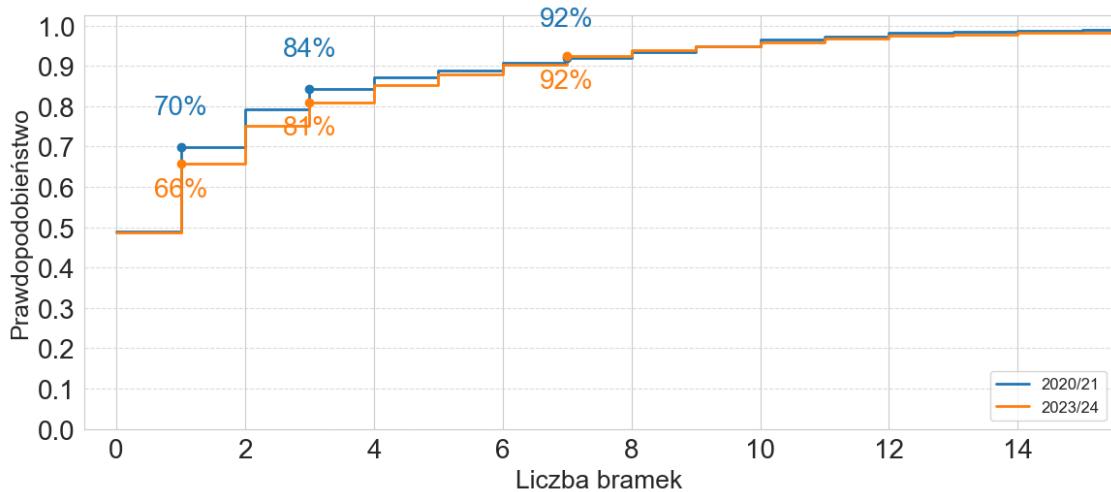
Analiza statystyk liczby goli strzelonych przez zawodników w sezonach 2020/21 i 2023/24 ujawnia kilka istotnych aspektów. Przede wszystkim widoczny jest wzrost średniej liczby goli z 1.85 do 2.06 na zawodnika, co sugeruje zwiększoną skuteczność ofensywną w sezonie z kibicami. Jednak najbardziej znaczącym spostrzeżeniem jest ogromna rozbieżność między średnią a średnią ucinaną (10%), która wynosiła odpowiednio 1.02 i 1.2 - ta różnica wyraźnie pokazuje, jak silnie wyniki całej ligi są zawyżane przez wąską grupę elitarnych napastników. Rozkład goli jest wyraźnie prawoskoñny, o czym świadczy fakt, że mediana utrzymuje się na poziomie zaledwie 1 gola, podczas gdy 25% zawodników nie strzeliło ani jednego gola. Jednocześnie wzrost wariancji z 11.14 do 13.11 oraz odchylenia standardowego z 3.34 do 3.62 wskazuje na większe zróżnicowanie między zawodnikami w sezonie 2023/24. Te statystyki potwierdzają, że Premier League charakteryzuje się nierównomiernym rozkładem skuteczności - podczas gdy większość graczy ma umiarkowane osiągnięcia, niewielka grupa napastników generuje znaczną część ligowych goli, a ich wpływ na średnią jest tak duży, że tradycyjna średnia arytmetyczna może wprowadzać w błąd co do typowej skuteczności przeciętnego zawodnika. Ze względu na tak wyraźne różnice w rozkładzie, warto dodatkowo przeanalizować gestoñ i dystrybuantę liczby goli, aby lepiej zrozumieć tę nierównomiernoñ.



Na podstawie tego wykresu ciężko wyciągnąć jednoznaczne wnioski – wartości dla obu sezonów są bardzo zbliżone. Może to wynikać z różnej liczby zawodników w analizowanych sezonach (2020/21: 532, 2023/24: 580). Dlatego dla lepszej porównywalności przedstawiamy wykres prawdopodobieństwa, który uwzględnia tę różnicę w liczebności prób.



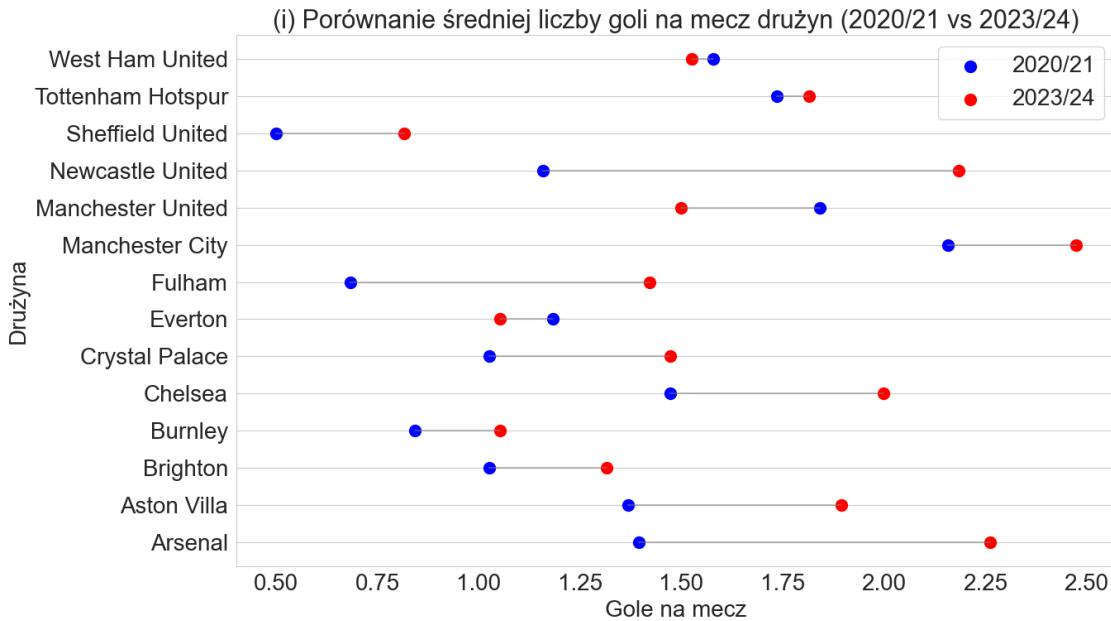
(h) Dystrybuanta liczby bramek strzelonych przez zawodników



Porównując rozkłady między sezonami, widać pewne charakterystyczne różnice. Pomimo podobnego kształtu rozkładów, w 2020/21 - rozgrywanym bez udziału publiczności, widać większe skupienie zawodników w przedziale 0-1 bramek oraz mniejszy udział strzelców w przedziałach 3-7 goli. To potwierdza hipotezę, że brak presji kibiców mógł sprzyjać lepszej organizacji defensywnej.

## 4.2 Skuteczność drużynowa

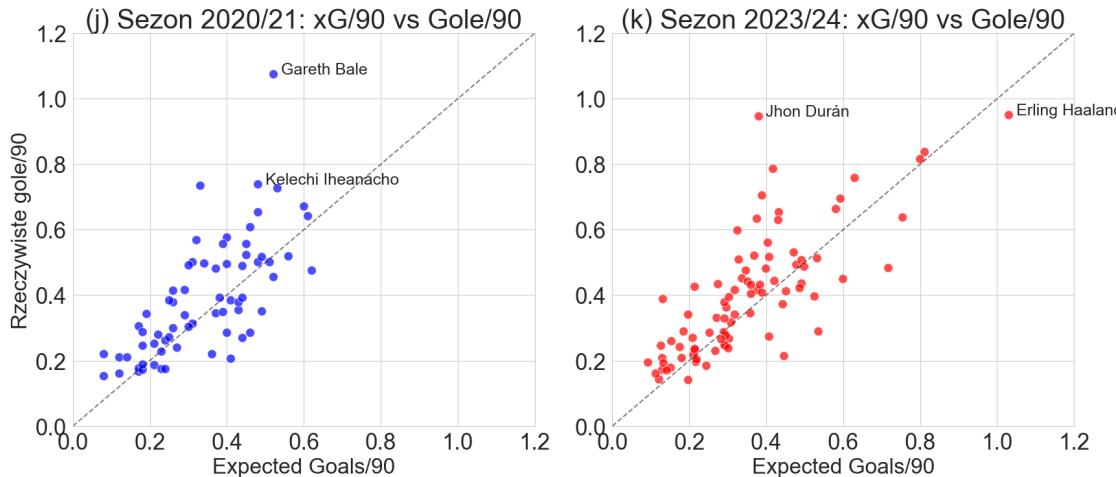
Aby dokładniej zbadać zaobserwowane różnice w rozkładzie bramek między sezonami, przeprowadzimy analizę z podziałem na poszczególne drużyny. Takie podejście pozwoli nam sprawdzić, czy zmniejszona liczba goli w sezonie 2020/21 była zjawiskiem powszechnym we wszystkich zespołach, czy może wynikała ze szczególnie dobrej gry defensywnej wybranych klubów. Jednocześnie zobaczymy, czy wzrost liczby strzelców w przedziale 3-7 goli w sezonie 2023/24 dotyczył całej ligi równomiernie, czy był napędzany przez konkretne, bardziej ofensywne drużyny.



Analiza z podziałem na drużyny wyraźnie pokazuje, że w sezonie 2023/24 dla ogromnej większości klubów liczba strzelonych bramek znaczco wzrosła w porównaniu z pandemicznym sezonem 2020/21. Szczególnie widoczny skok skuteczności odnotowały takie zespoły jak Fulham, Newcastle United i Arsenal, gdzie różnica w liczbie goli strzelonych przez zawodników tych drużyn między sezonami jest wyjątkowo wyraźna. Ten wzrost ofensywnej skuteczności w całej lidze, a zwłaszcza w wymienionych klubach, dodatkowo podkreśla, jak istotny wpływ na wyniki może mieć obecność kibiców na stadionach.

### 4.3 Czy napastnicy też grali lepiej bez kibiców?

Na sam koniec przeanalizujemy, czy zaobserwowane zmiany dotyczyły wyłącznie obrońców, czy również napastników. W tym celu porównamy wskaźnik xG (expected Goals) na 90 minut z rzeczywistą liczbą strzelonych goli na 90 minut dla obu sezonów. To porównanie pozwoli nam ocenić, czy piłkarze byli bardziej skuteczni w realizacji sytuacji bramkowych w warunkach braku kibiców. Aby wyniki były bardziej miarodajne, w analizie uwzględnimy wyłącznie tych zawodników, którzy rozegrali co najmniej 10 meczów w sezonie oraz strzelili minimum 5 goli. Takie zwężenie próby wyeliminuje przypadkowe wahania wynikające od sporadycznie grających zawodników.



Porównując wykresy xG na 90 minut z rzeczywistymi golami na 90 minut dla obu sezonów, widać uderzająco podobne rozkłady. Zarówno w sezonie 2020/21 rozgrywanym bez kibiców, jak i w sezonie 2023/24 z pełnymi stadionami, napastnicy wykazywali zbliżoną skuteczność w realizacji sytuacji bramkowych. Ta obserwacja sugeruje, że wpływ obecności publiczności na efektywność gry ofensywnej był marginalny. Można zatem wnioskować, że różnice w ogólnej liczbie bramek między sezonami wynikały raczej ze zmian w organizacji defensywnej drużyn niż ze zmiany formy napastników. Innymi słowy: kibice mogli wpływać na taktykę zespołów, ale nie na precyzję strzelców w bezpośrednią konfrontacją z bramkarzem.

## 5 Podsumowanie

### 5.1 Potwierdzenie głównej hipotezy

Badanie wyraźnie wykazało, że brak kibiców w sezonie 2020/21 istotnie wpłynął na:

- Lepszą organizację defensywą (mniej straconych bramek mimo podobnych wartości xG)
- Mniejszą liczbę żółtych kartek (średnio 2.11 vs 2.85 w sezonie 2023/24)
- Zmniejszoną skuteczność ofensywną (średnio 2.69 vs 3.28 gola/mecz z kibicami)

### 5.2 Odkrycie dotyczące napastników

Porównanie xG vs rzeczywiste gole (dla zawodników z min. 10 meczami i 5 golami) ujawniło:

- Brak istotnej różnicy w skuteczności między sezonami
- Wniosek: Kibice wpływali głównie na taktykę zespołów, a nie na precyzję strzelców

### 5.3 Wnioski ogólne

- Presja kibiców zwiększa intensywność gry (więcej fauli, kartek, ofensywnych akcji)
- “Sterylne” warunki sezonu 2020/21 sprzyjały defensywnemu zorganizowaniu
- Naturalny eksperyment pandemiczny dostarczył unikalnych danych o wpływie otoczenia na dynamikę gry

#### **5.4 Wartość naukowa**

Badanie potwierdza, że czynniki pozasportowe (jak obecność publiczności) mogą znacząco modyfikować:

- Statystyki dyscyplinarne
- Efektywność taktyczną
- Psychologię podejmowania decyzji na boisku